به نام خدا



دانشکده علوم ریاضی

پروژه درس آمار و کاربرد آن
نیم‌سال اول 06-05
استاد: دکتر علیشاهی

گزارش فاز اول | **آیدا عامری** | **403100202**

---

۱ منشأ داده و سازوکار جمع‌آوری

۱.۱ منبع رسمی و دوره زمانی جمع‌آوری داده

داده‌های این پژوهش از پیمایش ملی بررسی سلامت و تغذیه ایالات متحده آمریکا (NHANES) استخراج شده‌اند که توسط مرکز ملی آمار سلامت (NCHS)، زیرمجموعه مرکز کنترل و پیشگیری از بیماری‌ها (CDC) اجرا می‌شود. دوره زمانی مورد بررسی، چرخه اوت 2021 تا اوت 2023 است که فایل‌های آن با پسوند L_ نام‌گذاری شده‌اند. این چرخه نخستین انتشار رسمی داده‌های ملی NHANES پس از وقفه ناشی از همه‌گیری کووید-19 محسوب می‌شود. پیش از این، نمونه‌گیری چرخه 2019-2020 در مارس 2020 متوقف شده بود؛ پس از یک وقفه 16 ماهه، عملیات میدانی در اوت 2021 با یک طراحی نمونه بازنگری‌شده از سر گرفته شد تا ضمن حفظ اعتبار آماری، تماس‌های حضوری به حداقل برسد.

۲.۱ ماهیت مطالعه و سازوکار تولید داده

از دیدگاه روش‌شناسی آماری (مطابق فصل اول کتاب ووناکات)، این مجموعه داده حاصل یک پیمایش مقطعی (Cross-sectional Survey) و یک مطالعه کاملاً مشاهده‌ای (Observational Study) است. برخلاف آزمایش‌های تصادفی کنترل‌شده (RCT) که در آن‌ها پژوهشگر مداخله‌ای مانند مصرف سیگار یا ویپ را به صورت تصادفی به افراد تخصیص می‌دهد، در این مطالعه افراد صرفاً بر اساس رفتار طبیعی زندگی خود مشاهده، مصاحبه و آزمایش شده‌اند. بنابراین، روابط آماری استخراج‌شده نشان‌دهنده همبستگی (Association) بوده و به تنهایی اثبات‌کننده رابطه علی (Causal) مستقیم نیستند. سازوکار تولید داده در این چرخه شامل سه گام متوالی بوده است:

۱. **غربالگری اولیه خانوار (Household Screening):** برای کاهش تماس حضوری در دوره پساکرونا، ابتدا از طریق چهار نوبت ارسال پستی، از خانوارها دعوت شد تا پرسش‌نامه واجد شرایط بودن را به صورت اینترنتی، کاغذی یا تلفنی تکمیل کنند (Multi-mode screening) و مراجعه حضوری تنها برای خانوارهای بی‌پاسخ انجام شد.

۲. **مصاحبه جامع سلامت (Health Interview):** اطلاعات جمعیت‌شناختی، اقتصادی، تاریخچه مصرف سیگار (SMQ_L) و وضعیت دود داخل منزل (SMQFAM_L) توسط مصاحبه‌گران ثبت گردید.

۳. **معاینات فیزیکی و آزمایشگاهی (MEC Examination):** شرکت‌کنندگان به مراکز معاینه سیار (MEC) مراجعه کردند. در این مراکز، نمونه‌گیری خون وریدی (Phlebotomy) انجام شد و پرسش‌نامه حساس مصرف اخیر دخانیات و ویپ در 5 روز گذشته (SMQRTU_L) هم‌زمان با خون‌گیری تکمیل گردید. نمونه‌های سرم و خون کامل سپس در آزمایشگاه‌های مرجع برای سنجش دقیق متابولیت‌های نیکوتین، فلزات سنگین و شمارش سلول‌های خونی آنالیز شدند.

۳.۱ وضعیت دسترسی و محدودیت‌های اخلاقی داده

داده‌های NHANES به دو دسته فایل‌های عمومی (Public-Use) و فایل‌های محدود (RDC Only) تقسیم می‌شوند. در این پروژه صرفاً از هفت فایل عمومی و بدون محدودیت دسترسی (Use Constraints: None) با فرمت استاندارد SAS Transport (.XPT) استفاده شده است که میان سپتامبر 2024 تا اوت 2026 منتشر شده‌اند. برای حفظ محرمانگی هویت افراد در این فایل‌های عمومی، شناسه‌های جغرافیایی حذف شده، سن افراد 80 سال و بالاتر با کد سقف 80 (Top-coded) و نسبت درآمد به خط فقر بالاتر از 5 با عدد 5.0 ثبت شده است.

۲ واحد مشاهده و ساختار داده

۱.۲ تعریف واحد مشاهده و کلید اتصال

واحد مشاهده (Unit of Observation) و واحد تحلیل در تمامی هفت فایل این پروژه، یک فرد یا شرکت‌کننده انسانی (Individual Participant) است که با شماره توالی منحصربه‌فرد SEQN شناسایی می‌شود. در هر یک از این هفت فایل، هر سطر دقیقاً نماینده یک فرد یکتا است و SEQN نقش کلید اصلی (Primary Key) و کلید ادغام را ایفا می‌کند. بنابراین میان تمامی فایل‌های مورد استفاده ما یک رابطه یک‌به‌یک (One-to-One) در سطح فرد برقرار است (برخلاف فایل‌های غذایی مانند DR1IFF_L که چندسطری هستند و در دامنه این پژوهش قرار ندارند).

۲.۲ بررسی ساختارهای تکرارشونده و سلسله‌مراتبی

این مطالعه طولی (Longitudinal) نیست و هر فرد تنها یک بار در چرخه 2021-2023 آزمایش شده است؛ با این حال، در درون یک سطر، متغیرهایی مانند کوتینین (LBXCOT) و هیدروکسی‌کوتینین (LBXHCOT) از یک نمونه سرم واحد استخراج شده‌اند و از نظر بیولوژیکی وابسته‌اند. از سوی دیگر، نحوه انتخاب افراد دارای ساختار سلسله‌مراتبی و خوشه‌ای چهارمرحله‌ای (شهرستان، بخش، خانوار و فرد) است. افرادی که در یک خوشه جغرافیایی یا خانوار مشترک زندگی می‌کنند، ممکن است از نظر مواجهه‌های محیطی به یکدیگر شبیه‌تر باشند. این ساختار سلسله‌مراتبی در فایل DEMO_L از طریق واحد نمونه‌گیری اولیه ساختگی (SDMVPSU) و طبقه ساختگی (SDMVSTRA) کدگذاری شده است.

جدول ۱: ساختار فایل‌های مورد استفاده و ارتباط آن‌ها با واحد مشاهده

نام فایل	بخش (Component)	واحد هر سطر	کلید اتصال	متغیر وزن موجود در فایل
DEMO_L	جمعیت‌شناختی	یک فرد (Participant)	SEQN	WTMEC2YR ،WTINT2YR
SMQ_L	پرسش‌نامه تاریخچه سیگار	یک فرد (Participant)	SEQN	ندارد (استفاده از وزن پایه)
SMQRTU_L	پرسش‌نامه مصرف 5 روز اخیر	یک فرد (Participant)	SEQN	ندارد (پرسش در مرکز MEC)
SMQFAM_L	پرسش‌نامه دود منزل	یک فرد (Participant)	SEQN	ندارد (استفاده از وزن پایه)
COT_L	آزمایشگاه (سرم خون)	یک فرد (Participant)	SEQN	ندارد (هم‌تراز با خون‌گیری)
PBCD_L	آزمایشگاه (خون کامل)	یک فرد (Participant)	SEQN	WTPH2YR
CBC_L	آزمایشگاه (خون کامل)	یک فرد (Participant)	SEQN	WTPH2YR

۳ نمونه‌گیری، انتخاب و قابلیت تعمیم

۱.۳ طراحی نمونه‌گیری احتمالی و تغییرات دوره پساکرونا (2021-2023)

انتخاب افراد در NHANES یک نمونه‌گیری تصادفی ساده (SRS) نیست، بلکه یک نمونه‌گیری احتمالی چهارمرحله‌ای، طبقه‌بندی‌شده و خوشه‌ای است: (۱) انتخاب 30 شهرستان یا واحد اولیه (PSU)، (۲) انتخاب بخش‌های جغرافیایی

(Segments)، (۳) انتخاب واحدهای مسکونی و خانوارها، و (۴) انتخاب افراد واجد شرایط درون خانوار. بر اساس راهنمای تحلیلی CDC، طراحی نمونه در چرخه 2021-2023 دچار دو تغییر بنیادین نسبت به دوره‌های پیشین شده است:

۱. **حذف بیش‌نمونه‌گیری (Oversampling) اقلیت‌های نژادی و کم‌درآمد:** در دوره‌های قبل، برای افزایش دقت برآورد در اقلیت‌ها، بسیاری از خانوارها پس از غربالگری کنار گذاشته می‌شدند (Walk-aways). در دوره 2021-2023 برای کاهش مراجعات حضوری، این پیش‌تخصیص حذف شد و در هر خانوار واجد شرایط حداقل یک بزرگسال انتخاب گردید. پیامد آماری این تغییر، افزایش سهم سفیدپوستان غیرهیسپانیک و کاهش حجم نمونه خام اقلیت‌های نژادی است.

۲. **انتخاب کامل سالمندان و کودکان در درون خانوار:** در این چرخه، تمامی اعضای خانوار در بازه سنی 0 تا 19 سال و 60 سال و بالاتر با احتمال 100% انتخاب شدند، در حالی که بزرگسالان 20 تا 59 ساله به صورت تصادفی (1 یا 2 نفر از هر خانوار) انتخاب گردیدند. این امر باعث بیش‌نمایی چشمگیر سالمندان بالای 60 سال در نمونه خام شده است.

۲.۳ تورش عدم پاسخ، وزن‌دهی و دامنه تعمیم‌پذیری

در چرخه 2021-2023، نرخ پاسخ‌دهی بدون وزن کاهش یافت؛ به طوری که نرخ پاسخ به غربالگری 65.6%، مشارکت در مصاحبه 34.6% و حضور در مرکز معاینات (MEC) 25.7% گزارش شد (در مقایسه با 51.0% و 46.9% در دوره پیشاکرونا). همچنین برخی مراجعه‌کنندگان به کلینیک از دادن نمونه خون وریدی خودداری کردند. برای رفع تورش عدم پاسخ (Nonresponse Bias) و جبران شانس نابرابر انتخاب، مرکز NCHS برای نخستین بار وزن اختصاصی دو ساله خون‌گیری (WTPH2YR) را منتشر کرده است. بدون اعمال این وزن، نتایج صرفاً توصیف‌کننده نمونه خام (با بیش‌نمایی سالمندان و سفیدپوستان) است؛ اما با اعمال وزن WTPH2YR، نتایج قابلیت تعمیم معتبر به کل جمعیت بزرگسال غیرنظامی و غیرنهادی ایالات متحده آمریکا (U.S. civilian noninstitutionalized population) در بازه اوت 2021 تا اوت 2023 را خواهد داشت.

۴ طبقه‌بندی متغیرها و مقیاس اندازه‌گیری

انتخاب شاخص‌های خلاصه عددی، نمودارها و مدل‌های استنباطی مستقیماً به مقیاس اندازه‌گیری متغیرها وابسته است. متغیرهای پاسخ شامل غلظت کوتینین سرم (LBXCOT)، هیدروکسی‌کوتینین (LBXHCOT)، کادمیوم خون (LBXBCD)، سرب خون (LBXBPB)، هموگلوبین (LBXHGB) و شمارش گلبول‌های سفید (LBXWBCSI) همگی از نوع کمی پیوسته (Continuous) و در مقیاس نسبی (Ratio Scale) هستند؛ زیرا دارای صفر مطلق و معنادار بوده و امکان اعمال تبدیل لگاریتمی و رگرسیون خطی (OLS) را فراهم می‌کنند.

متغیر توضیحی اصلی یعنی «گروه مصرف دخانیات» (Smoking_Group) که از ترکیب منطقی وضعیت فعلی سیگار (SMQ040)، مصرف سیگار در 5 روز اخیر (SMQ681) و مصرف ویپ در 5 روز اخیر (SMQ846) ساخته می‌شود، یک متغیر طبقه‌ای اسمی (Nominal) چهارسطحی (غیرسیگاری، انحصاری ویپ، انحصاری سیگار و مصرف دوگانه) است که در فاز اول با جدول فراوانی و نمودار جعبه‌ای، در فاز سوم با تحلیل واریانس (ANOVA) و در فاز چهارم با متغیرهای مجازی (Dummy) تحلیل می‌شود. متغیرهای تعداد روز و تعداد نخ مصرفی (SMQ710، SMQ720 و SMQ849) و تعداد سیگاری‌های منزل (SMD470) از نوع کمی گسسته (شمارشی) بوده و کدهای کامنت آزمایشگاهی (LBDCOTLC و LBDBCDLC) متغیرهایی طبقه‌ای و دودویی (0: بالای حد تشخیص، 1: زیر حد تشخیص LOD) هستند.

۵ ممیزی کیفیت داده و تصمیم‌گیری‌های پالایشی

پیش از تعریف جمعیت تحلیلی و محاسبات توصیفی، مجموعه داده حاصل از ادغام هفت فایل خام (شامل 11,933 شرکت‌کننده در کل پیمایش و 7,809 بزرگسال 20 سال و بالاتر) در ماژول src/data_cleaner.py از پنج جنبه کلیدی ممیزی گردید.

جدول ۲: طبقه‌بندی، مقیاس اندازه‌گیری و نقش متغیرهای پژوهش

نام متغیر	فایل مبدأ	شرح متغیر و واحد اندازه‌گیری	نوع متغیر	مقیاس آماری	نقش در تحلیل
LBXCOT	COT_L	غلظت کوتینین سرم (ng/mL)	کمی پیوسته	نسبی (Ratio)	پاسخ اصلی (Y_1)
LBXBCD	PBCD_L	غلظت کادمیوم خون (ug/L)	کمی پیوسته	نسبی (Ratio)	پاسخ اصلی (Y_2)
LBXHCOT	COT_L	هیدروکسی‌کوتینین سرم (ng/mL)	کمی پیوسته	نسبی (Ratio)	پاسخ مکمل / حساسیت
LBXBPB	PBCD_L	غلظت سرب خون (ug/dL)	کمی پیوسته	نسبی (Ratio)	پاسخ مکمل / همبستگی
LBXHGB	CBC_L	غلظت هموگلوبین خون (g/dL)	کمی پیوسته	نسبی (Ratio)	پیامد بالینی مکمل
LBXWBCSI	CBC_L	شمارش گلبول سفید (1000 cells/uL)	کمی پیوسته	نسبی (Ratio)	پیامد التهابی مکمل
SMQ040	SMQ_L	وضعیت فعلی کشیدن سیگار	طبقه‌ای	ترتیبی (Ordinal)	ساخت گروه مصرف (X)
SMQ681	SMQRTU_L	مصرف تنباکوی تدخینی در 5 روز اخیر	طبقه‌ای	دودویی (Binary)	ساخت گروه مصرف (X)
SMQ846	SMQRTU_L	مصرف سیگار الکترونیکی در 5 روز اخیر	طبقه‌ای	دودویی (Binary)	ساخت گروه مصرف (X)
SMQ710	SMQRTU_L	تعداد روز مصرف سیگار در 5 روز اخیر	کمی گسسته	نسبی (شمارشی)	توضیحی شدت مصرف
SMQ720	SMQRTU_L	تعداد نخ سیگار در روزهای مصرف	کمی گسسته	نسبی (شمارشی)	توضیحی شدت مصرف
SMQ849	SMQRTU_L	تعداد روز مصرف ویپ در 5 روز اخیر	کمی گسسته	نسبی (شمارشی)	توضیحی شدت مصرف
RIDAGEYR	DEMO_L	سن فرد در زمان غربالگری (سال)	کمی پیوسته	نسبی (Ratio)	کنترلی (Confounder)
RIAGENDR	DEMO_L	جنسیت فرد (مرد / زن)	طبقه‌ای	اسمی دودویی	کنترلی / زیرگروه
DMDEDUC2	DEMO_L	سطح تحصیلات بزرگسالان (5 سطح)	طبقه‌ای	ترتیبی (Ordinal)	کنترلی (Confounder)
INDFMPIR	DEMO_L	نسبت درآمد خانوار به خط فقر (0 تا 5)	کمی پیوسته	نسبی (Ratio)	کنترلی (Confounder)
SMD470	SMQFAM_L	تعداد افراد سیگاری داخل منزل	کمی گسسته	نسبی (شمارشی)	کنترلی (دود دست‌دوم)
LBXBSE	PBCD_L	غلظت سلنیوم خون (ug/L)	کمی پیوسته	نسبی (Ratio)	کنترلی (آنتی‌اکسیدان)
SMQ863	SMQRTU_L	مصرف داروهای ترک نیکوتین (5 روز اخیر)	طبقه‌ای	دودویی (Binary)	معیار پالایش و خروج
SMQ845	SMQRTU_L	مصرف قلیان در 5 روز اخیر	طبقه‌ای	دودویی (Binary)	معیار پالایش و خروج
SMQ851	SMQRTU_L	مصرف تنباکوی بدون دود (5 روز اخیر)	طبقه‌ای	دودویی (Binary)	معیار پالایش و خروج
LBDCOTLC	COT_L	کد حد تشخیص آزمایشگاه برای کوتینین	طبقه‌ای	دودویی (Binary)	ممیزی کیفیت / حساسیت
LBDBCDLC	PBCD_L	کد حد تشخیص آزمایشگاه برای کادمیوم	طبقه‌ای	دودویی (Binary)	ممیزی کیفیت / حساسیت
WTPH2YR	PBCD_L	وزن نمونه‌گیری 2 ساله خون‌گیری	کمی پیوسته	نسبی (Ratio)	وزن‌دهی آماری نمونه

۱.۵ بررسی رکوردهای تکراری و کدهای ویژه «نامعلوم / پاسخ نداده»

ممیزی سطرهای تکراری و شناسه SEQN نشان داد که در هر هفت فایل خام و در دیتافریم ادغام‌شده، تعداد رکوردهای تکراری دقیقاً برابر با 0 است؛ بنابراین نیازی به حذف یا تجمیع سطری نبوده و فرض استقلال سطرها برقرار است.

در استاندارد کدگذاری NHANES، موارد «امتناع از پاسخ» (Refused) با کدهای قراردادی 7، 77 یا 777 و پاسخ‌های «نمی‌دانم» (Don't Know) با کدهای 9، 99 یا 999 ثبت می‌شوند. تصمیم تحلیلی ما شناسایی تمامی این کدها (مجموعاً 55 مورد در 13 متغیر پرسش‌نامه‌ای) و تبدیل آن‌ها به مقدار گمشده استاندارد (NaN) پیش از هرگونه تحلیل بود؛ زیرا باقی ماندن اعدادی نظیر 999 در تعداد سیگار روزانه (SMD650) یا کد 9 در سطح تحصیلات (DMDEDUC2) باعث انحراف شدید میانگین و واریانس می‌شود.

۲.۵ بررسی مقادیر غیرممکن، خطاهای ذخیره‌سازی و مقادیر سانسورشده آزمایشگاهی (LOD)

بررسی دامنه تغییرات متغیرهای کمی تایید کرد که هیچ مقدار منفی یا غیرممکن بیولوژیکی در داده وجود ندارد (تعداد مقادیر منفی برابر با 0). در بازخوانی فایل‌های SAS (.XPT)، عدد صفر مطلق گاهی به صورت اعداد ممیز شناور بسیار کوچک (5.39×10^{-79}) ثبت می‌شود که با اعمال شرط آستانه‌ای ($|x| < 10^{-10}$) همگی به 0.0 دقیق تبدیل شدند. همچنین سانسور از بالا (Top-coding) در سن (80 سال)، نسبت درآمد به فقر (5.0) و سیگار روزانه ماه اخیر (95 نخ) حفظ شد.

در متغیرهای سم‌شناسی، زمانی که غلظت بیومارکر کمتر از حد تشخیص دستگاه (Below LOD) باشد، کد کامنت متناظر مقدار 1 می‌گیرد و آزمایشگاه CDC مقدار قراردادی $\frac{\text{LOD}}{\sqrt{2}}$ را درج می‌کند. ممیزی زیرجمعیت بزرگسالان نشان داد که در کوتینین و هیدروکسی‌کوتینین حدود 39.5% مشاهدات زیر حد تشخیص هستند، در کادمیوم تنها 0.78% (45 نفر) زیر حد تشخیص بوده و در سرب و سلنیوم 100% نمونه‌ها بالای حد تشخیص بوده‌اند. تصمیم تحلیلی ما در فازهای اول تا چهارم، حفظ مقادیر جایگزین‌شده

جدول ۳: ممیزی کدهای ویژه امتناع و نامعلوم در متغیرهای پرسش‌نامه‌ای و تبدیل آن‌ها به NaN

نام متغیر	شرح متغیر	کدهای بررسی‌شده	تعداد امتناع	تعداد نامعلوم	مجموع تبدیل به NaN
DMDEDUC2	سطح تحصیلات بزرگسالان	7, 9	0	11	11
SMQ020	مصرف حداقل 100 نخ سیگار در عمر	7, 9	7	7	14
SMQ040	وضعیت فعلی کشیدن سیگار	7, 9	0	0	0
SMD650	میانگین نخ سیگار در روز (30 روز اخیر)	777, 999	0	9	9
SMQ681	مصرف تنباکوی تدخینی در 5 روز اخیر	7, 9	1	2	3
SMQ710	تعداد روز مصرف سیگار در 5 روز اخیر	7, 9, 77, 99	1	1	2
SMQ720	تعداد نخ سیگار در روز (5 روز اخیر)	777, 999	1	1	2
SMQ845	مصرف قلیان در 5 روز اخیر	7, 9	0	1	1
SMQ846	مصرف سیگار الکترونیکی در 5 روز اخیر	7, 9	1	4	5
SMQ849	تعداد روز مصرف ویپ در 5 روز اخیر	7, 9, 77, 99	0	1	1
SMQ851	مصرف تنباکوی بدون دود در 5 روز اخیر	7, 9	2	2	4
SMQ863	مصرف داروهای ترک نیکوتین (5 روز اخیر)	7, 9	2	0	2
SMD470	تعداد افراد سیگاری در داخل منزل	77, 99, 777, 999	0	1	1

$\frac{\text{LOD}}{\sqrt{2}}$ است؛ زیرا حذف 2,180 فرد زیر LOD باعث حذف عمده غیرسیگاری‌ها و ایجاد تورش انتخاب شدید می‌شود و جایگزینی با صفر نیز مانع از تبدیل لگاریتمی ($\log_{10}$) می‌گردد (تحلیل حساسیت در فاز پنجم انجام خواهد شد).

جدول ۴: ممیزی مقادیر زیر حد تشخیص آزمایشگاهی (Below LOD) در زیرجمعیت بزرگسالان (20 سال و بالاتر)

نام متغیر	بیومارکر و واحد اندازه‌گیری	متغیر کد کامنت	تعداد آزمایش‌شده	تعداد (درصد) زیر LOD	مقدار جایگزین ($\frac{\text{LOD}}{\sqrt{2}}$)
LBXCOT	کوتینین سرم (ng/mL)	LBDCOTLC	5,521	(39.49%) 2,180	0.007
LBXHCOT	هیدروکسی‌کوتینین سرم (ng/mL)	LBDHCOLC	5,522	(39.42%) 2,177	0.003
LBXBCD	کادمیوم خون (ug/L)	LBDBCDLC	5,770	(0.78%) 45	0.046
LBXBPB	سرب خون (ug/dL)	LBDBPBLC	5,770	(0.00%) 0	ندارد (LOD بالای 100%)
LBXBSE	سلنیوم خون (ug/L)	LBDBSELC	5,770	(0.00%) 0	ندارد (LOD بالای 100%)

۳.۵ بررسی ناسازگاری‌های منطقی

سه آزمون سازگاری منطقی میان پرسش‌نامه‌ها اجرا شد: (۱) نقض الگوی پرش پرسش‌نامه (Skip Pattern) میان SMQ020=2 و SMQ040 برابر با 0 بود؛ (۲) نقض بازه تعداد روز مصرف در 5 روز اخیر (> 5 days) برابر با 0 بود؛ (۳) مقایسه مصاحبه منزل (SMQ_L) با پرسش‌نامه کلینیک (SMQRTU_L) نشان داد که 188 نفر، با وجود معرفی خود به عنوان غیرسیگاری یا ترک‌کرده در منزل، در زمان خون‌گیری در کلینیک اعلام کرده‌اند که در 5 روز گذشته محصول تدخینی مصرف کرده‌اند (SMQ681=1). تصمیم تحلیلی ما اولویت دادن به مصرف فعال در 5 روز منتهی به خون‌گیری است (به دلیل نیمه‌عمر 16 تا 20 ساعته کوتینین) تا این 188 نفر به اشتباه وارد گروه غیرسیگاری یا انحصاری ویپ نشوند.

۴.۵ ممیزی داده‌های گمشده و استراتژی برخورد با آن‌ها

مقایسه کل نمونه (11,933 نفر) با بزرگسالان (7,809 نفر) نشان می‌دهد که بخش عمده مقادیر خالی، «گمشدگی ساختاری» (Structural Missingness) ناشی از سن یا شرطی بودن سوالات است؛ مثلاً گمشدگی تحصیلات (DMDEDUC2) در کل نمونه 34.78% است اما در بزرگسالان تنها 0.33% (26 نفر) است. همچنین خالی بودن تعداد سیگاری‌های داخل منزل (SMD470) با 78.42% ناشی از آن است که این سوال فقط از خانوارهای دارای فرد سیگاری پرسیده شده است (برای سایر خانوارها مقدار واقعی برابر با 0 نفر است).

راهبرد برخورد با داده‌های گمشده: (۱) برای متغیرهای آزمایشگاهی و وزن خون‌گیری (26% تا 29% گمشدگی ناشی از عدم حضور در کلینیک)، افراد فاقد داده در مرحله تعریف جمعیت تحلیلی حذف می‌شوند و تورش عدم حضور آن‌ها توسط وزن کالیبره‌شده WTPH2YR جبران می‌گردد (زیرا جایگزینی مصنوعی روی متغیر پاسخ مجاز نیست)؛ (۲) گمشدگی ساختاری SMD470 برای

جدول ۵: ممیزی داده‌های گمشده و دامنه مقادیر متغیرها در زیرجمعیت بزرگسالان (20 سال و بالاتر، $N = 7,809$)

نام متغیر	شرح متغیر	تعداد معتبر	تعداد گمشده	درصد گمشدگی	بازه مقادیر (کمینه تا بیشینه)
RIDAGEYR	سن فرد (سال)	7,809	0	0.00%	20.0 تا 80.0
RIAGENDR	جنسیت (1=مرد، 2=زن)	7,809	0	0.00%	1 تا 2
RIDRETH3	نژاد و قومیت (6 سطح)	7,809	0	0.00%	1 تا 7
DMDEDUC2	سطح تحصیلات بزرگسالان	7,783	26	0.33%	1 تا 5
INDFMPIR	نسبت درآمد به خط فقر	6,489	1,320	16.90%	0.00 تا 5.00
SMQ020	مصرف 100 نخ سیگار در عمر	7,780	29	0.37%	1 تا 2
SMQ040	وضعیت فعلی سیگار (مشروط)	3,233	4,576	58.60%	1 تا 3
SMQ681	مصرف تدخینی در 5 روز اخیر	5,248	2,561	32.80%	1 تا 2
SMQ710	روزهای مصرف سیگار (5 روز اخیر)	774	7,035	90.09%	1 تا 5
SMQ720	نخ سیگار در روز (5 روز اخیر)	774	7,035	90.09%	1 تا 40
SMQ846	مصرف ویپ در 5 روز اخیر	5,246	2,563	32.82%	1 تا 2
SMQ849	روزهای مصرف ویپ (5 روز اخیر)	314	7,495	95.98%	1 تا 5
SMD470	افراد سیگاری داخل منزل (مشروط)	1,685	6,124	78.42%	0 تا 2
LBXCOT	غلظت کوتینین سرم (ng/mL)	5,521	2,288	29.30%	0.007 تا 1090.00
LBXHCOT	هیدروکسی‌کوتینین سرم (ng/mL)	5,522	2,287	29.29%	0.003 تا 804.00
LBXBCD	غلظت کادمیوم خون (ug/L)	5,770	2,039	26.11%	0.046 تا 8.379
LBXBPB	غلظت سرب خون (ug/dL)	5,770	2,039	26.11%	0.087 تا 48.070
LBXBSE	غلظت سلنیوم خون (ug/L)	5,770	2,039	26.11%	86.00 تا 867.70
LBXHGB	غلظت هموگلوبین خون (g/dL)	5,768	2,041	26.14%	6.30 تا 18.60
LBXWBCSI	شمارش گلبول سفید (1000 cells/uL)	5,768	2,041	26.14%	2.10 تا 18.40
WTPH2YR	وزن 2 ساله خون‌گیری	6,064	1,745	22.35%	0.00 تا 241728.86

خانوارهای غیرسیگاری با 0 جایگزین شد؛ (۳) برای متغیر کنترلی درآمد (INDFMPIR با 16.90% عدم پاسخ)، در فازهای اول تا سوم از حذف سطری پرهیز می‌شود (Available-case) تا توان آماری حفظ شود و در فاز چهارم و پنجم تحلیل موارد کامل و تحلیل حساسیت انجام می‌گردد.

۶ جدول‌های فراوانی و توزیع تجربی

۱.۶ توزیع فراوانی متغیرهای طبقه‌ای و الگوهای کلیدی

جدول زیر توزیع فراوانی، درصد از کل و درصد معتبر (Valid Percent) متغیرهای طبقه‌ای اصلی را در زیرجمعیت بزرگسالان ($N = 7,809$) نشان می‌دهد:

دو الگوی مهم در جدول فوق عبارتند از: (۱) نامتوازن بودن طبیعی حجم چهار گروه مصرف (Class Imbalance) که در آن غیرسیگاری‌ها 79.46% و مصرف‌کنندگان دوگانه 2.31% (117 نفر) هستند؛ با این حال، وجود بیش از 100 مشاهده در هر گروه، توان آماری کافی بر اساس قضیه حد مرکزی فراهم می‌کند و ضرورت استفاده از آزمون ولش (Welch's ANOVA) را در فاز سوم نشان می‌دهد. (۲) سهم بالای سفیدپوستان (58.33%)، تحصیل‌کردگان دانشگاهی (64.18% در سطوح 4 و 5) و زنان (55.33%) در نمونه خام که بازتاب حذف بیش‌نمونه‌گیری اقلیت‌ها و مشارکت انتخابی در دوره پساکرونا است.

۲.۶ خلاصه توزیع تجربی متغیرهای کمی بر پایه صدک‌ها

جدول زیر صدک‌های تجربی (P_5 تا P_{95}) را برای متغیرهای کمی نشان می‌دهد. الگوی کلیدی، ثبات کوتینین روی 0.007 ng/mL تا صدک P_{25} (اثر سانسور از چپ LOD) و سپس پرش ناگهانی و چند هزار برابری آن میان صدک هفتاد و پنجم ($P_{75} = 0.810$) و صدک نودم ($P_{90} = 221.000 ng/mL$) است که مرز بیولوژیکی میان جمعیت غیرسیگاری (80% پایین توزیع) و سیگاری‌های فعال (20% بالای توزیع) را آشکار می‌سازد.

جدول ۶: توزیع فراوانی و درصد متغیرهای طبقه‌ای اصلی در زیرجمعیت بزرگسالان ($N = 7,809$)

متغیر طبقه‌ای	سطح / طبقه (Category)	فراوانی (n)	درصد کل	درصد معتبر
گروه مصرف دخانیات (Smoking_Group)	1. Non-Smoker (غیرسیگاری)	4,031	51.62%	79.46%
	2. Exclusive Vape (انحصاری ویپ)	168	2.15%	3.31%
	3. Exclusive Cigarette (انحصاری سیگار)	757	9.69%	14.92%
	4. Dual User (مصرف دوگانه)	117	1.50%	2.31%
	نامشخص / خارج از شمول (Missing)	2,736	35.04%	—
جنسیت (RIAGENDR)	زن (Female) / مرد (Male)	3,488 / 4,321	44.67% / 55.33%	44.67% / 55.33%
سطح تحصیلات (DMDEDUC2)	1. کمتر از کلاس نهم	373	4.78%	4.79%
	2. کلاس نهم تا یازدهم (بدون دیپلم)	666	8.53%	8.56%
	3. دیپلم دبیرستان یا معادل (GED)	1,749	22.40%	22.47%
	4. فوق‌دیپلم یا کالج ناتمام (Some college)	2,370	30.35%	30.45%
	5. فارغ‌التحصیل دانشگاه (لیسانس و بالاتر)	2,625	33.62%	33.73%
	گمشده (Missing)	26	0.33%	—
نژاد و قومیت (RIDRETH3)	سفیدپوست غیرهیسپانیک (Non-Hispanic White)	4,555	58.33%	58.33%
	سیاه‌پوست غیرهیسپانیک (Non-Hispanic Black)	995	12.74%	12.74%
	سایر هیسپانیک‌ها / مکزیکی–آمریکایی	545 / 780	6.98% / 9.99%	6.98% / 9.99%
	چندنژادی یا سایر / آسیایی غیرهیسپانیک	422 / 512	5.40% / 6.56%	5.40% / 6.56%
مواجهه با دود منزل	بدون مواجهه (0) / دارای مواجهه (≥ 1)	697 / 7,112	8.93% / 91.07%	8.93% / 91.07%

جدول ۷: خلاصه توزیع تجربی متغیرهای کمی بر اساس صدک‌ها در زیرجمعیت بزرگسالان

نام متغیر	N	کمینه	P_5	P_{10}	(Q_1) P_{25}	(Med) P_{50}	(Q_3) P_{75}	P_{90}	P_{95}	بیشینه
LBXCOT	5,521	0.007	0.007	0.007	0.007	0.016	0.810	221.000	318.000	1090.000
LBXHCOT	5,522	0.003	0.003	0.003	0.003	0.007	0.300	91.990	152.000	804.000
LBXBCD	5,770	0.046	0.096	0.118	0.171	0.269	0.463	0.853	1.285	8.379
LBXBPB	5,770	0.087	0.270	0.333	0.483	0.751	1.172	1.748	2.362	48.070
LBXBSE	5,770	86.000	145.500	152.200	164.025	177.600	192.975	209.100	221.655	867.700
LBXHGB	5,768	6.300	11.400	12.100	13.000	13.900	14.900	15.700	16.200	18.600
LBXWBCSI	5,768	2.100	4.200	4.600	5.500	6.600	8.000	9.500	10.600	18.400
RIDAGEYR	7,809	20.000	24.000	28.000	38.000	57.000	68.000	76.000	80.000	80.000
INDFMPIR	6,489	0.000	0.430	0.740	1.400	2.790	4.970	5.000	5.000	5.000

۷ شاخص‌های مرکز و پراکندگی و منطق انتخاب معیار

بر اساس فصل دوم کتاب ووناکات، میانگین حسابی نقش «مرکز ثقل» (Center of Gravity) توزیع را دارد و به همراه انحراف معیار (SD) به شدت نسبت به دنباله‌های بلند و نقاط پرت حساس است؛ در حالی که میانه و دامنه بین‌چارکی (IQR) تنها به رتبه‌های میانی وابسته‌اند و مقاوم (Robust) هستند.

جدول ۸: شاخص‌های مرکز، پراکندگی، چولگی و معیار منتخب متغیرهای کمی در زیرجمعیت بزرگسالان

نام متغیر	تعداد (N)	میانگین	SD	میانه (Q_2)	Q_1	Q_3	IQR	چولگی	CV	معیار منتخب
LBXCOT	5,521	50.268	119.312	0.016	0.007	0.810	0.803	2.93	2.37	میانه و IQR
LBXHCOT	5,522	23.612	63.429	0.007	0.003	0.300	0.297	4.15	2.69	میانه و IQR
LBXBCD	5,770	0.424	0.517	0.269	0.171	0.463	0.292	5.10	1.22	میانه و IQR
LBXBPB	5,770	0.990	1.143	0.751	0.483	1.172	0.689	15.99	1.15	میانه و IQR
LBXBSE	5,770	180.707	30.065	177.600	164.025	192.975	28.950	5.99	0.17	هر دو معیار
LBXHGB	5,768	13.880	1.483	13.900	13.000	14.900	1.900	-0.40	0.11	میانگین و SD
LBXWBCSI	5,768	6.912	2.033	6.600	5.500	8.000	2.500	1.03	0.29	هر دو معیار
RIDAGEYR	7,809	53.628	17.527	57.000	38.000	68.000	30.000	-0.23	0.33	میانگین و SD
INDFMPIR	6,489	2.901	1.660	2.790	1.400	4.970	3.570	-0.03	0.57	میانگین و SD
SMQ720	774	10.349	7.891	9.000	5.000	15.000	10.000	1.36	0.76	میانه و IQR

دلایل انتخاب معیار برای هر دسته از متغیرها:

۱. **سموم و متابولیت‌های نیکوتین (LBXCOT، LBXHCOT، LBXBCD، LBXBPB):** میانگین و SD در مقیاس خام برای این متغیرها کاملاً گمراه‌کننده‌اند. در کوتینین سرم، میانگین (50.268 ng/mL) بیش از 3,140 برابر بزرگ‌تر از میانه (0.016 ng/mL) است و انحراف معیار (119.312) بیش از دو برابر میانگین است (CV = 2.37)؛ زیرا دنباله راستِ سیگاری‌ها مرکز ثقل را به فضایی می‌کشاند که هیچ فرد واقعی در آن حضور ندارد. در کادمیوم (= Skewness 5.10) و سرب (Skewness = 15.99) نیز به دلیل چولگی شدید، تنها «میانه و IQR» معیار معتبر در مقیاس خام هستند.

۲. **سلنیوم (LBXBSE) و گلبول سفید (LBXWBCSI):** با وجود چولگی 5.99 در سلنیوم (ناشی از چند فرد با مصرف مکمل بالا تا 867.7 ug/L)، میانگین (180.707) و میانه (177.600) بسیار نزدیک بوده و CV = 0.17 است؛ لذا گزارش هم‌زمان هر دو معیار برای نشان دادن تقارن بدنه اصلی و کنترل نقاط پرت مناسب است.

۳. **هموگلوبین (LBXHGB)، سن (RIDAGEYR) و درآمد (INDFMPIR):** به دلیل تنظیم هموستاتیک هموگلوبین (میانگین 13.880 و میانه 13.900، چولگی 0.40-) و کران‌دار بودن سن و درآمد (چولگی 0.23- و 0.03-)، میانگین و انحراف معیار کاراترین معیار هستند. در تعداد نخ سیگار روزانه (SMQ720) به دلیل چولگی راست (1.36)، میانه (9.0 نخ) و IQR (10.0 نخ) ارجحیت دارند.

۸ مصورسازی آماری توزیع‌ها و روابط

چهار نمودار استاندارد بر روی زیرمجموعه بزرگسالان دارای گروه دخانیات مشخص ($N = 5,073$) طراحی و در پوشه figures/ ذخیره گردید. در تمامی شکل‌ها، واحدها و عناوین کامل بوده و از برش گمراه‌کننده محورها پرهیز شده است.

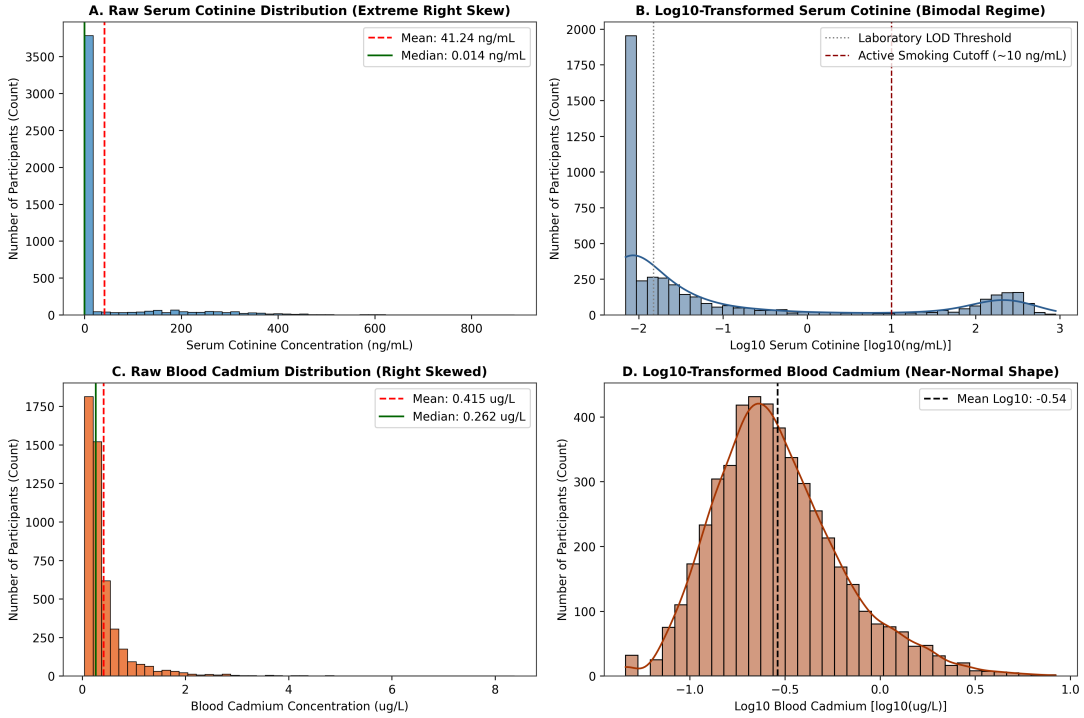
۱.۸ نمودار ۱ و ۲: توزیع‌های خطی در برابر لگاریتمی و نمودارهای جعبه‌ای گروه‌ها

در شکل ۱، پنل‌های A و C فشردگی شدید مشاهدات در مجاورت صفر و فاصله زیاد میانگین (خط چین قرمز: 41.24 ng/mL و 0.415 ug/L) از میانه (خط سبز: 0.014 و 0.262) را در مقیاس خام نشان می‌دهند. در پنل B، تبدیل $\log_{10}$ رژیم دووجهی

(Bimodal) کوتینین را آشکار می‌سازد (قله چپ در -2.15 برای غیرسیگاری‌ها و قله راست بالای آستانه ~ 10 ng/mL برای مصرف‌کنندگان فعال). در پنل D نیز تبدیل لگاریتمی کادمیوم، توزیع را به شکل زنگوله‌ای متقارن (با میانگین لگاریتمی -0.54) درآورده است.

در شکل ۲ (نمودار جعبه‌ای)، پنل A نشان می‌دهد که جعبه و میانه کوتینین در هر سه گروه مصرف‌کننده (Exclusive Vape، Exclusive Cigarette و Dual User) در یک تراز بالا ($\log_{10} \approx +2.25$) قرار دارند؛ اما در پنل B (کادمیوم خون)، جعبه سبز رنگ مصرف‌کنندگان انحصاری ویپ دقیقاً هم‌تراز با گروه غیرسیگاری ($\log_{10} \approx -0.65$) باقی مانده، در حالی که جعبه سیگاری‌های سنتی و دوگانه به شدت به سمت بالا جهش کرده‌اند.

Figure 1: Empirical Distributions of Primary Biomarkers on Linear vs. Logarithmic Scales (NHANES 2021-2023)



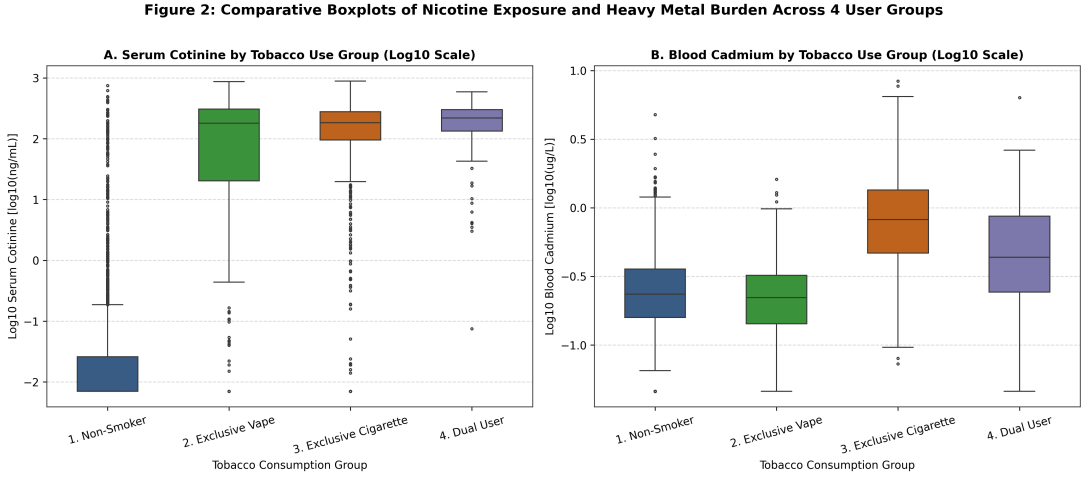
شکل ۱: توزیع تجربی کوتینین سرم و کادمیوم خون در مقیاس خطی خام (چپ) و لگاریتمی پایه 10 (راست).

۲.۸ نمودار ۳ و ۴: ترکیب دموگرافیک گروه‌ها و رابطه دوز–پاسخ

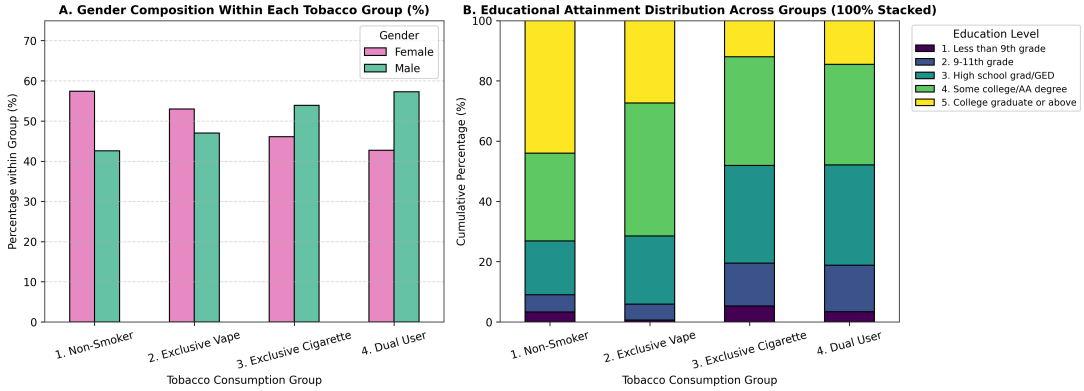
در شکل ۳ (پنل A)، سهم زنان در غیرسیگاری‌ها (57.4%) و ویپرها (53.0%) بیشتر است، اما در سیگاری‌های سنتی (53.9%) و مصرف دوگانه (57.3%) مردان اکثریت دارند. در پنل B (نمودار انباشته 100% تحصیلات)، سهم فارغ‌التحصیلان دانشگاه (بخش زرد) از حدود 44% در غیرسیگاری‌ها و 27% در ویپرها، به حدود 12% تا 15% در سیگاری‌های سنتی و دوگانه سقوط می‌کند. در شکل ۴ نیز رابطه دوز روزانه سیگار (SMQ720) با کوتینین و کادمیوم، علاوه بر نمایش پدیده گرد کردن اعداد حول مضارب 5 و 10 نخ (Digit Preference)، یک شیب خطی کاملاً مثبت و صعودی را برای هر دو بیومارکر تایید می‌کند.

۹ مقایسه توصیفی اولیه میان گروه‌های مطالعه

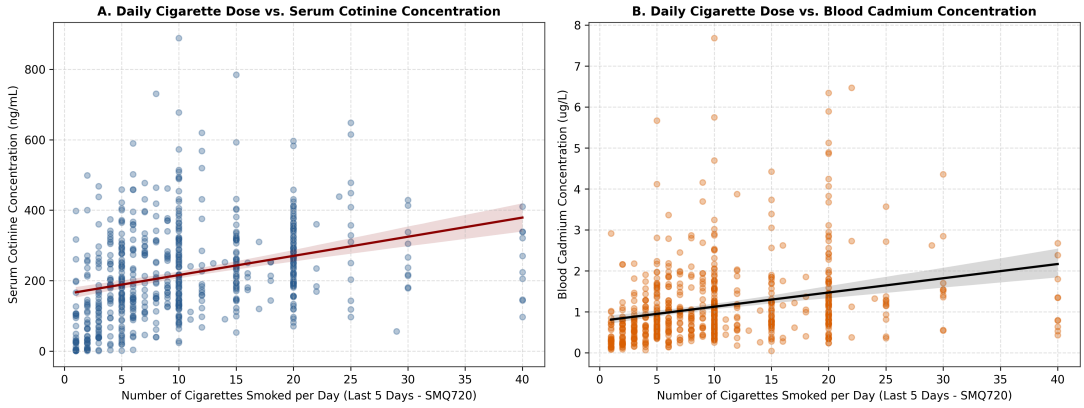
جدول زیر مقایسه توصیفی میانه (IQR) و میانگین متغیرهای کمی را در چهار گروه مصرف دخانیات (بدون ادعای استنباطی) نشان می‌دهد:



شکل ۲: نمودار جعبه‌ای غلظت لگاریتمی کوتینین سرم (الف) و کادمیوم خون (ب) به تفکیک چهار گروه مصرف دخانیات.



شکل ۳: ترکیب جنسیتی (الف) و توزیع سطح تحصیلات (ب) در درون هر یک از چهار گروه مصرف دخانیات.



شکل ۴: نمودار پراکنش و خط روند رابطه دوز مصرف روزانه سیگار با غلظت کوتینین سرم (الف) و کادمیوم خون (ب).

جدول ۹: مقایسه توصیفی میانه (IQR) و میانگین متغیرهای کمی در چهار گروه مصرف دخانیات

متغیر (واحد)	1. Non-Smoker میانه (IQR) | میانگین	2. Exclusive Vape میانه (IQR) | میانگین	3. Exclusive Cigarette میانه (IQR) | میانگین	4. Dual User میانه (IQR) | میانگین
(ng/mL) LBXCOT	2.972 | (0.019) 0.007	187.476 | (287.900) 180.500	195.491 | (182.700) 183.000	215.231 | (168.500) 219.000
(ng/mL) LBXHCOT	1.525 | (0.008) 0.003	84.101 | (126.810) 62.300	93.781 | (97.825) 75.750	103.620 | (94.500) 75.300
(ug/L) LBXBCD	0.290 | (0.199) 0.235	0.280 | (0.179) 0.222	1.082 | (0.880) 0.819	0.710 | (0.626) 0.436
(ug/dL) LBXBPB	0.938 | (0.636) 0.718	0.746 | (0.489) 0.623	1.222 | (0.805) 0.991	1.132 | (0.546) 0.735
(ug/L) LBXBSE	181.862 | (29.200) 178.100	181.024 | (23.775) 180.800	177.445 | (29.700) 176.400	180.383 | (29.150) 176.600
(g/dL) LBXHGB	13.826 | (1.800) 13.800	14.033 | (2.100) 14.000	14.291 | (2.000) 14.400	14.420 | (1.500) 14.600
(1000/uL) LBXWBCSI	6.727 | (2.300) 6.500	7.169 | (3.000) 6.800	7.667 | (2.800) 7.500	7.870 | (2.800) 7.500
(سال) RIDAGEYR	55.191 | (29.000) 59.000	38.464 | (25.250) 34.000	53.165 | (22.000) 56.000	40.256 | (25.000) 36.000
(نسبت) INDFMPIR	3.237 | (3.215) 3.350	2.911 | (3.035) 2.850	2.052 | (2.080) 1.680	2.291 | (2.375) 1.955

تحلیل یافته‌های توصیفی و شواهد مخدوش‌کنندگی (Confounding):

۱. **جذب بالای نیکوتین در ویپرها و اوج مصرف در گروه دوگانه:** میانه کوتینین در انحصاری ویپ (180.500 ng/mL) و انحصاری سیگار (183.000 ng/mL) تقریباً برابر است و در مصرف دوگانه به اوج خود (219.000 ng/mL) می‌رسد، در حالی که در غیرسیگاری‌ها 0.007 ng/mL است.

۲. **واگرایی عظیم در کادمیوم (LBXBCD) و سرب (LBXBPB) و روند پلکانی التهاب (LBXWBCSI):** میانه کادمیوم در سیگاری‌های سنتی (0.819 ug/L) بیش از 3.7 برابر مصرف‌کنندگان انحصاری ویپ (0.222 ug/L) است و سطح کادمیوم ویپرها کاملاً منطبق بر غیرسیگاری‌ها (0.235 ug/L) قرار دارد. همچنین شمارش گلبول سفید و هموگلوبین از غیرسیگاری (6.500 و 13.800) به سمت ویپ (6.800 و 14.000) و سیگار و دوگانه (7.500 و 14.600) افزایش پلکانی دارند.

۳. **تبیین معمای کادمیوم با متغیر مخدوش‌کننده سن (فصل اول ووناکات):** چرا میانه کادمیوم و سرب در ویپرها حتی از غیرسیگاری‌ها اندکی کمتر است (0.222 در برابر 0.235) و در مصرف دوگانه کمتر از سیگار انحصاری است (0.436 در برابر 0.819)؟ پاسخ در سطر سن (RIDAGEYR) نهفته است: میانه سن ویپرها (34.0 سال) و دوگانه‌ها (36.0 سال) بیش از 20 سال کمتر از غیرسیگاری‌ها (59.0 سال) و سیگاری‌های سنتی (56.0 سال) است! از آنجا که کادمیوم و سرب نیمه‌عمر تجمع 10 تا 30 ساله در بدن دارند، جوان بودن ویپرها سطح پایه فلزات سنگین آن‌ها را کاهش داده است. همچنین میانه نسبت درآمد به فقر در سیگاری‌ها (1.680) بسیار کمتر از غیرسیگاری‌ها (3.350) است. این یافته‌ها اثبات می‌کنند که کنترل هم‌زمان سن، درآمد و تحصیلات در رگرسیون فاز چهارم کاملاً حیاتی است.

۱۰ نهایی‌سازی سؤال آماری پژوهش (تسک ۱۰)

بر اساس شناخت تجربی حاصل از تسک‌های 5 تا 9، سؤال آماری کارت پروژه در سه محور تدقیق شد: (۱) تغییر مقیاس متغیرهای پاسخ اصلی به مقیاس لگاریتمی ($\log_{10}$) جهت رفع چولگی شدید، (۲) محدود کردن جامعه هدف به بزرگسالان 20 سال و بالاترِ پالایش‌شده از تداخل قلیان، تنباکوی جویدنی و داروهای ترک نیکوتین در 5 روز اخیر، و (۳) الزامی شدن کنترل آماری سن و طبقه اقتصادی‌ـ‌اجتماعی.

صورت نهایی سؤال آماری: «در جمعیت بزرگسالان غیرنظامی و غیرنهادی ایالات متحده (20 سال و بالاتر) در دوره پساکرونا (2021-2023)، پس از کنترل اثر متغیرهای مخدوش‌کننده سن (RIDAGEYR)، جنسیت (RIAGENDR)، تحصیلات (DMDEDUC2)، نسبت درآمد به فقر (INDFMPIR)، مواجهه با دود منزل (SMD470) و سلنیوم خون (LBXBSE) و با اعمال وزن خون‌گیری (WTPH2YR): آیا مصرف‌کنندگان انحصاری ویپ در مقایسه با مصرف‌کنندگان سیگار سنتی و دوگانه، با وجود دریافت سطوح مشابه یا بالاتری از نیکوتین (LBXCOT و LBXHCOT)، دارای بار تجمع کادمیوم و سرب خونی (LBXBCD و LBXBPB) و التهاب سیستمیک (LBXWBCSI) به طور معنادار پایین‌تری هستند و آیا سطح فلزات سنگین خون آن‌ها با غیرسیگاری‌ها تفاوت معناداری دارد؟»

این مجموعه داده به دلیل دارا بودن سنجش‌های عینی آزمایشگاهی، پرسش‌نامه هم‌زمان 5 روز اخیر در کلینیک، حجم نمونه کافی در هر چهار گروه ($n > 100$ در کوچک‌ترین گروه) و وزن اختصاصی WTPH2YR، برای پاسخ به این سؤال کاملاً مناسب و کافی است.

۱۱ الزام الف‌ـ۱: شناسایی فایل‌ها، کلید ادغام و گزارش ابعاد

در ماژول src/data_loader.py، هفت فایل خام با پایه قرار دادن فایل DEMO_L (11,933 نفر) از طریق کلید مشترک و یکتای فردی SEQN به روش ادغام از چپ (Left Join) به یکدیگر متصل شدند تا چارچوب کلی نمونه حفظ شود. همچنین اشتراک تجمعی (Cumulative Inner Join) محاسبه گردید که نشان می‌دهد پس از اتصال پرسش‌نامه کلینیک (SMQRTU_L)، اشتراک کامل روی 7,199 نفر تثبیت می‌شود؛ زیرا تمامی پاسخ‌دهندگان به این پرسش‌نامه در فایل‌های آزمایشگاهی نیز حضور دارند:

جدول ۱۰: ابعاد فایل‌های خام پیش از ادغام و گزارش گام‌به‌گام تعداد افراد قبل و بعد از هر مرحله ادغام روی کلید SEQN

گام ادغام	نام فایل	شرح ماژول	کلید ادغام	سطرها (SEQN یکتا)	ستون کل (منتخب)	سطرهای Left Join	اشتراک تجمعی (Inner)
گام ۱ (پایه)	DEMO_L	جمعیت‌شناختی و وزن پایه	SEQN	11,933 (11,933)	27 (10)	11,933	11,933
گام ۲	SMQ_L	تاریخچه سیگار (+12 سال)	SEQN	9,015 (9,015)	9 (4)	11,933	9,015
گام ۳	SMQRTU_L	مصرف 5 روز اخیر در MEC	SEQN	7,199 (7,199)	21 (9)	11,933	7,199
گام ۴	SMQFAM_L	افراد سیگاری داخل منزل	SEQN	11,933 (11,933)	3 (2)	11,933	7,199
گام ۵	COT_L	کوتینین سرم (+3 سال)	SEQN	8,493 (8,493)	5 (5)	11,933	7,199
گام ۶	PBCD_L	فلزات سنگین خون (+1 سال)	SEQN	8,727 (8,727)	17 (8)	11,933	7,199
گام ۷	CBC_L	شمارش سلول‌های خونی (+1 سال)	SEQN	8,727 (8,727)	23 (3)	11,933	7,199

۱۲ الزام الف‌ـ۲: شناسایی وزن و طرح نمونه‌گیری

برخلاف نمونه‌گیری تصادفی ساده که در آن شانس انتخاب هر فرد یکسان ($\pi_i = \frac{n}{N}$) است، در طرح چهارمرحله‌ای NHANES هر فرد نماینده تعداد متفاوتی از افراد جمعیت ایالات متحده است ($w_i \neq w_j$). این تفاوت وزن ناشی از سه عامل است: (۱) معکوس احتمال نابرابر انتخاب ($w_{i,\text{base}} = \frac{1}{\pi_i}$)، به طوری که بزرگسالان 20 تا 59 ساله به دلیل انتخاب تصادفی در خانوار، وزن پایه بزرگ‌تری نسبت به سالمندان +60 سال (که 100% انتخاب شده‌اند) دریافت می‌کنند؛ (۲) ضرب شدن در ضریب تعدیل عدم پاسخ در زیرگروه‌ها؛ و (۳) کالیبراسیون نهایی (Raking) با آمار سرشماری رسمی آمریکا.

بر اساس «اصل کوچک‌ترین زیرجمعیت» (Smallest Subpopulation Principle)، از میان سه وزن موجود (WTINT2YR، WTMEC2YR و WTPH2YR)، متغیر **WTPH2YR** (وزن دو ساله خون‌گیری) تنها وزن صحیح برای این پژوهش است. جدول زیر نشان می‌دهد که با وجود کاهش تعداد بزرگسالان از مصاحبه (7,809 نفر) به خون‌گیری (5,792 نفر)، مجموع وزن‌ها در هر سه متغیر دقیقاً برابر با 245,061,169 نفر (کل جمعیت بزرگسال غیرنظامی آمریکا) ثابت مانده است و در WTPH2YR هر فرد نماینده 4,391.8 تا 241,728.9 نفر (نسبت 55.0 برابر) است:

جدول ۱۱: مشخصات و دامنه تغییرات وزن‌های نمونه‌گیری در زیرجمعیت بزرگسالان (20 سال و بالاتر)

متغیر وزن	تعداد وزن مثبت	مجموع وزن‌ها (جمعیت بزرگسال آمریکا)	کمینه وزن	میانه وزن	میانگین وزن	بیشینه وزن	نسبت بیشینه به کمینه
WTINT2YR	7,809	245,061,169	4,584.5	25,135.1	31,381.9	170,968.3	37.3
WTMEC2YR	6,064	245,061,169	4,581.6	31,816.9	40,412.5	227,108.3	49.6
WTPH2YR	5,792	245,061,169	4,391.8	33,332.9	42,310.3	241,728.9	55.0

۱۳ الزام الف_۳: مقایسه خلاصه‌های خام و وزن‌دار

در این بخش، مطابق با فرمول میانگین موزون در فصل دوم کتاب ووناکات ($\bar{X}_w = \frac{\sum w_i X_i}{\sum w_i}$)، شاخص‌های کمی و نسبت‌های طبقه‌ای در جمعیت تحلیلی نهایی ($N = 4,655$) در دو حالت بدون وزن (Unweighted) و وزن‌دار (Weighted با WTPH2YR) مقایسه شده‌اند:

جدول ۱۲: مقایسه میانگین و میانه خام (Unweighted) و وزن‌دار (WTPH2YR) برای متغیرهای کمی در جمعیت تحلیلی

متغیر و شرح	تعداد (n)	میانگین خام	میانگین وزن‌دار	اختلاف میانگین	تغییر نسبی (%)	میانه خام	میانه وزن‌دار
RIDAGEYR (سن کل نمونه تحلیلی)	4,655	54.133	48.997	-5.136	-9.49%	58.000	49.000
INDFMPIR (نسبت درآمد به فقر)	4,103	3.071	3.139	+0.067	+2.20%	3.080	3.220
LBXCOT (کوتینین سرم - کل)	4,655	41.248	41.714	+0.465	+1.13%	0.014	0.016
LBXBCD (کادمیوم خون - کل)	4,655	0.408	0.378	-0.030	-7.24%	0.262	0.238
LBXBPB (سرب خون - کل)	4,655	0.973	0.891	-0.082	-8.41%	0.742	0.672
LBXHGB (هموگلوبین خون)	4,638	13.909	14.000	+0.091	+0.65%	13.900	14.100
LBXWBCSI (گلبول سفید خون)	4,638	6.890	6.899	+0.009	+0.13%	6.600	6.600
LBXCOT در گروه 2. Exclusive Vape	146	187.476	201.020	+13.544	+7.22%	180.500	191.000
LBXBCD در گروه 2. Exclusive Vape	146	0.274	0.236	-0.038	-13.76%	0.218	0.183
LBXCOT در گروه 3. Exclusive Cigarette	672	195.491	182.137	-13.354	-6.83%	183.000	175.000
LBXBCD در گروه 3. Exclusive Cigarette	672	1.059	1.011	-0.048	-4.54%	0.794	0.764
LBXCOT در گروه 4. Dual User	103	215.231	218.321	+3.091	+1.44%	219.000	227.000
LBXBCD در گروه 4. Dual User	103	0.694	0.604	-0.090	-12.96%	0.432	0.378

جدول ۱۳: مقایسه نسبت‌ها (درصدهای) خام و وزن‌دار (WTPH2YR) برای متغیرهای طبقه‌ای در جمعیت تحلیلی ($N = 4,655$)

متغیر طبقه‌ای	طبقه / زیرگروه	تعداد در نمونه (n)	درصد خام (%)	درصد وزن‌دار (%)	اختلاف (W - Unw)
گروه مصرف دخانیات	1. Non-Smoker (غیرسیگاری)	3,734	80.21%	79.42%	-0.80%
	2. Exclusive Vape (انحصاری ویپ)	146	3.14%	3.86%	+0.73%
	3. Exclusive Cigarette (انحصاری سیگار)	672	14.44%	13.99%	-0.44%
	4. Dual User (مصرف دوگانه)	103	2.21%	2.73%	+0.52%
گروه سنی	سالمندان (60 سال و بالاتر)	2,178	46.79%	31.82%	-14.97%
نژاد و قومیت	سفیدپوست غیرهیسپانیک / سیاه‌پوست	499 / 2,896	10.72% / 62.21%	10.49% / 62.62%	-0.23% / +0.40%

تحلیل اثر وزن‌دهی: (۱) به دلیل انتخاب 100% سالمندان در طراحی نمونه، افراد +60 سال در نمونه خام 46.79% بودند؛ با اعمال وزن WTPH2YR، سهم آن‌ها 14.97% کاهش یافته و به نسبت واقعی جامعه (31.82%) بازمی‌گردد. در نتیجه، میانگین سن از 54.133 به 48.997 سال (5.136- سال) و میانه سن از 58.0 به 49.0 سال کاهش می‌یابد و به تبع آن، میانگین کل کادمیوم (7.24%-) و سرب خون (8.41%-) در جامعه کم می‌شود. (۲) با افزایش وزن جوانان، شیوع انحصاری ویپ از 3.14% به 3.86% و مصرف دوگانه از 2.21% به 2.73% افزایش می‌یابد. (۳) در مقایسه درون‌گروهی وزن‌دار، میانگین کوتینین ویپرها به 201.020 ng/mL (میانه 191.000) می‌رسد که حتی از سیگاری‌های سنتی (182.137 ng/mL) بالاتر است، در حالی که میانگین وزن‌دار کادمیوم در سیگاری‌ها (1.011 ug/L) بیش از 4.2 برابر ویپرها (0.236 ug/L) باقی می‌ماند.

۱۴ الزام الف_۴: تعریف دقیق جمعیت تحلیلی و گزارش ریزش نمونه

در ماژول src/survey_design.py، پنج معیار ورود و خروج متوالی بر روی دیتافریم اولیه (11,933 نفر) اعمال شد: (۱) ورود بزرگسالان 20 سال و بالاتر (حذف 4,124 کودک و نوجوان زیر 20 سال)، (۲) داشتن وزن خون‌گیری مثبت WTPH2YR > 0 (حذف 2,017 نفر)، (۳) کامل بودن هر دو پیامد اصلی کوتینین LBXCOT و کادمیوم LBXBCD (حذف 272 نفر)، (۴) حذف مصرف‌کنندگان داروهای ترک نیکوتین (SMQ863=1)، قلیان (SMQ845=1) و تنباکوی جویدنی (SMQ851=1) در 5

روز اخیر جهت رفع تداخل بیولوژیکی (حذف 152 نفر)، و (۵) داشتن اطلاعات کامل پرسش‌نامه دخانیات برای تخصیص قطعی به یکی از 4 گروه (حذف 713 نفر).

جدول ۱۴: جریان تعریف جمعیت تحلیلی و تعداد دقیق افراد حذف‌شده در هر مرحله

گام	شرح معیار ورود / خروج اعمال‌شده	افراد باقی‌مانده	حذف‌شده در گام	حذف تجمعی	درصد ماندگاری
گام ۰	کل شرکت‌کنندگان در فایل ادغام‌شده اولیه (DEMO_L)	11,933	0	0	100.00%
گام ۱	محدودیت سنی: بزرگسالان 20 سال و بالاتر (RIDAGEYR ≥ 20)	7,809	4,124	4,124	65.44%
گام ۲	داشتن وزن خون‌گیری مثبت و معتبر (WTPH2YR > 0)	5,792	2,017	6,141	48.54%
گام ۳	موجود بودن هر دو پیامد اصلی کوتینین (LBXCOT) و کادمیوم (LBXBCD)	5,520	272	6,413	46.26%
گام ۴	حذف مصرف‌کنندگان داروهای ترک نیکوتین، قلیان و تنباکوی جویدنی	5,368	152	6,565	44.98%
گام ۵	اطلاعات کامل جهت طبقه‌بندی در یکی از 4 گروه (جمعیت تحلیلی نهایی)	4,655	713	7,278	39.01%

در نهایت، جمعیت تحلیلی نهایی شامل **4,655** بزرگسال واجد شرایط است که در چهار گروه مطالعه به صورت **3,734** نفر غیرسیگاری (80.21% خام | 79.42% وزن‌دار)، **146** نفر مصرف‌کننده انحصاری ویپ (3.14% خام | 3.86% وزن‌دار)، **672** نفر مصرف‌کننده انحصاری سیگار سنتی (14.44% خام | 13.99% وزن‌دار) و **103** نفر مصرف‌کننده دوگانه (2.21% خام | 2.73% وزن‌دار) توزیع شده‌اند و مبنای استنباط‌های فازهای بعدی را تشکیل می‌دهند.